

Proyecto 1: Segmentación y clasificación del estado de madurez de tomates

INFO1185: Inteligencia Artificial

13 de septiembre de 2026

Resumen

Se implementa un sistema reproducible para segmentar tomates mediante K-Means y clasificar su estado de madurez mediante un clasificador bayesiano gaussiano. El experimento usa 62 imágenes del conjunto local, 31 maduras y 31 inmaduras, con partición por imagen y una semilla fija. Se comparan las siete combinaciones no vacías de los canales RGB mediante Jaccard, se extraen descriptores RGB/HSV, y se contrastan tres estrategias: Bayes con selección basada en análisis exploratorio, Bayes con selección secuencial hacia adelante (SFS) y PCA seguido de Bayes.

La mejor combinación de segmentación en desarrollo fue RB, con Jaccard medio 0.560. En el test, el mayor AUC correspondió a Bayes + SFS (0.929), aunque las tres estrategias alcanzaron la misma exactitud (0.846). PCA retuvo tres componentes, que explican el 95.16 % de la varianza del entrenamiento.

Índice

1. Problema y objetivo	2
2. Datos y protocolo experimental	2
2.1. Estructura observada	2
2.2. Partición y control de fuga de información	3
3. Exploración de datos	3
4. Segmentación mediante K-Means	4
4.1. Configuración	4
4.2. Comparación de canales	5
5. Extracción y selección de características	6
5.1. Selección basada en análisis	6
5.2. Selección secuencial hacia adelante	6
6. Clasificación bayesiana y regla de decisión	7
7. PCA + Bayes	8
8. Relación entre segmentación y clasificación	9

9. Respuestas a las preguntas centrales	9
10.Conclusiones y limitaciones	10

1. Problema y objetivo

El objetivo es construir un flujo que reciba una imagen RGB de uno o más tomates, separe automáticamente el fruto del fondo y determine si el tomate pertenece a la clase *maduro* o *inmaduro*. El trabajo combina:

1. aprendizaje no supervisado para producir la máscara del fruto mediante K-Means;
2. extracción de características únicamente dentro de la máscara estimada;
3. selección de variables por dos estrategias distintas;
4. decisión bayesiana con umbral seleccionado en validación;
5. reducción de dimensionalidad mediante PCA y comparación final.

El flujo experimental es:

Imagen RGB/RGBA $\rightarrow$ redimensionamiento común $\rightarrow$ K-Means para R, G, B, RG, RB, GB y RGB $\rightarrow$ Jaccard contra anotación $\rightarrow$ características RGB/HSV del fruto $\rightarrow$ selección o PCA $\rightarrow$ Bayes $\rightarrow$ umbral de Youden $\rightarrow$ test final.

2. Datos y protocolo experimental

2.1. Estructura observada

El directorio contiene dos clases, **ripe** y **unripe**. Cada clase contiene un subdirectorio **images** y otro **masks**; para cada imagen se encontró exactamente una máscara con el sufijo **_mask.png**. La tabla resume la inspección de los archivos.

Cuadro 1: Estructura del conjunto de datos.

Elemento	Resultado
Imágenes totales	62
Tomates maduros / inmaduros	31 / 31
Máscaras encontradas	62 de 62
Canales originales	60 RGB y 2 RGBA
Altura original	200–5200 píxeles
Ancho original	250–7792 píxeles
Área anotada media, maduro	0.399
Área anotada media, inmaduro	0.315

Las resoluciones son heterogéneas y las imágenes RGBA se convierten a RGB descartando el canal alfa. Para controlar costo y mantener el experimento reproducible, cada imagen y su máscara se redimensionan manteniendo la proporción hasta un lado máximo de 256 píxeles. La máscara usa interpolación del vecino más cercano; la imagen usa interpolación de área. No se mezclan píxeles de una imagen con otra.

2.2. Partición y control de fuga de información

La partición se hace antes de extraer características y por imagen, no por píxel. Se emplea la semilla 20260913 y estratificación por clase. Por redondeo entero, la partición obtenida es cercana a 60/20/20:

Cuadro 2: Partición estratificada por imagen.

Clase	Entrenamiento	Validación	Test	Total
Maduro	18	7	6	31
Inmaduro	18	6	7	31
Total	36	13	13	62
Porcentaje	58.1 %	21.0 %	21.0 %	100 %

La segmentación, la selección de características y PCA se fijan usando solamente entrenamiento y/o validación. El umbral se selecciona sobre validación y el modelo final se reentrena con entrenamiento más validación antes de evaluar una sola vez el test. El conjunto de test no participa en decisiones de diseño.

3. Exploración de datos

La exploración de color usa las máscaras de referencia solo para describir la diferencia entre fruto y fondo durante desarrollo. Para cada imagen se calculan estadísticos de los píxeles de la región anotada y del complemento. La tabla muestra promedios sobre las imágenes de entrenamiento y validación.

Cuadro 3: Promedios de píxel en desarrollo. H está en grados y S/V en $[0, 1]$.

Clase	Región	R	G	B	H	S	V
Maduro	Fruto	189.17	71.61	42.68	48.35	0.798	0.744
Maduro	Fondo	146.32	137.46	119.67	87.21	0.362	0.612
Inmaduro	Fruto	140.09	165.38	66.50	78.14	0.631	0.650
Inmaduro	Fondo	149.22	153.95	126.17	64.58	0.332	0.624




Figura 1: Distribución de las seis características calculadas sobre la máscara estimada. La separación de las clases es especialmente clara en R, G y H.

Los tomates maduros presentan un canal R alto y canales G/B bajos, mientras que los inmaduros presentan un canal G alto. El tono H también cambia: el promedio del fruto maduro es cercano a 48° , frente a 78° en el inmaduro. Saturación y valor aportan información, pero son más sensibles a iluminación, reflejos y fondo. Por ello, la selección basada en análisis usa $[R, G, H]$: son variables con una diferencia de clase grande y una interpretación directa, evitando añadir variables redundantes sin evidencia adicional.

4. Segmentación mediante K-Means

4.1. Configuración

Para cada imagen y cada combinación se ajusta un K-Means independiente con:

- $k = 2$ clusters: fruto y fondo;
- inicialización **k-means++**, 10 reinicios;
- máximo de 300 iteraciones y tolerancia 10^{-4} ;
- semilla 20260913;
- muestra uniforme de hasta 12 000 píxeles para ajustar K-Means y predicción sobre todos los píxeles redimensionados.

La etiqueta interna del cluster no tiene significado, por lo que no se usa el orden de los centroides. Para seleccionar el cluster del fruto sin consultar la anotación, se calcula un puntaje de objeto que combina coherencia del componente conectado mayor, centralidad, saturación, valor HSV, un prior suave de área y una penalización por tocar el borde. La máscara de referencia se usa después solamente para calcular Jaccard:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}. \quad (1)$$

4.2. Comparación de canales

La elección de la combinación se realiza con el promedio del conjunto de desarrollo (entrenamiento más validación). El test se muestra solo como evaluación final.

Cuadro 4: Jaccard medio y desviación estándar. La selección se basa en desarrollo.

Combinación	Desarrollo: media	Desarrollo: DE	Test: media	Test: DE
R	0.533	0.221	0.442	0.300
G	0.512	0.247	0.409	0.302
B	0.511	0.296	0.490	0.335
RG	0.553	0.232	0.483	0.328
RB	0.560	0.254	0.465	0.361
GB	0.515	0.287	0.457	0.351
RGB	0.547	0.257	0.455	0.348




Figura 2: Comparación de Jaccard en desarrollo para las siete combinaciones. Las barras de error son desviaciones estándar entre imágenes.

RB se selecciona porque alcanza el mejor promedio de desarrollo (0.560). La ventaja sobre RG (0.553) y RGB (0.547) es pequeña, por lo que no se debe interpretar como una superioridad universal: el test baja a 0.465 y mantiene una variabilidad alta. En este conjunto, B ayuda a distinguir tomates brillantes u oscuros en escenas donde R y G por sí solos se confunden con el fondo, pero K-Means con solo dos clusters no separa siempre fondos complejos, hojas, platos o madera.




Figura 3: Ejemplos representativos para RB: imagen, máscara de referencia, máscara estimada y superposición. Las imperfecciones muestran la limitación de usar color global con solo dos clusters.

5. Extracción y selección de características

Con la máscara RB seleccionada, cada imagen queda representada por el promedio de los píxeles del fruto estimado:

$$\mathbf{x} = [\bar{R}, \bar{G}, \bar{B}, \bar{H}, \bar{S}, \bar{V}]. \quad (2)$$

RGB se conserva en la escala 0–255; H se expresa en grados y S/V en $[0, 1]$. Antes de cada clasificador se aplica estandarización $z = (x - \mu)/\sigma$ ajustada solo con entrenamiento. La segmentación estimada se usa tanto en entrenamiento como en validación y test, por lo que la clasificación mide el sistema completo y no una versión artificial con máscaras perfectas.

5.1. Selección basada en análisis

Se selecciona $[R, G, H]$. R captura la dominante roja del maduro, G la dominante verde del inmaduro y H resume la posición de color de manera complementaria. Esta decisión se fundamenta en los promedios de la Tabla 3 y en las distribuciones de la Figura 2.

5.2. Selección secuencial hacia adelante

Como segunda estrategia se implementa SFS con validación cruzada estratificada de cinco particiones sobre entrenamiento. En cada paso se añade la variable que maximiza el AUC medio de un pipeline estandarización + GaussianNB. Para reducir la inestabilidad de una muestra pequeña, se permite continuar mientras el AUC no caiga más de 0.01; se detiene a lo más en cuatro variables. El orden obtenido fue:

Cuadro 5: Trazas de SFS sobre entrenamiento.

Paso	Variable añadida	AUC medio CV
1	G	0.988
2	R	0.983
3	B	0.983
4	S	0.983

El subconjunto final es $[G, R, B, S]$. Coincide parcialmente con la selección por análisis: ambas conservan R y G. SFS incorpora B y S, posiblemente porque capturan variaciones de iluminación, reflejos y saturación que no aparecen con la misma claridad en la inspección de medias.

6. Clasificación bayesiana y regla de decisión

Para cada subconjunto se ajusta GaussianNB. Para la clase positiva maduro, el clasificador produce $s(\mathbf{x}) = P(y = 1 \mid \mathbf{x})$. La regla de decisión es

$$\hat{y} = \begin{cases} 1 & s(\mathbf{x}) \geq \tau, \\ 0 & s(\mathbf{x}) < \tau. \end{cases} \quad (3)$$

Esto es equivalente a una razón de verosimilitudes con un umbral que incorpora las probabilidades a priori y los costos de error. El umbral τ se fija con el índice de Youden sobre validación:

$$J_Y(\tau) = \text{sensibilidad}(\tau) - \text{FPR}(\tau), \quad \tau^* = \arg \max_{\tau} J_Y(\tau). \quad (4)$$

Youden se elige porque busca simultáneamente sensibilidad y especificidad, sin asumir un costo clínico o comercial específico para cada tipo de error. Luego el modelo se reentrena con entrenamiento más validación, conservando τ^* , y se evalúa sobre test.

Cuadro 6: Evaluación con el umbral seleccionado por Youden.

Modelo	Conjunto	τ^*	AUC	Exactitud	Sens.	Espec.	F1
Bayes + análisis	Validación	0.984	0.976	0.923	0.857	1.000	0.923
Bayes + SFS	Validación	0.357	0.952	0.923	1.000	0.833	0.875
PCA + Bayes	Validación	0.827	0.952	0.923	0.857	1.000	0.923
Bayes + análisis	Test	0.984	0.833	0.846	0.833	0.857	0.833
Bayes + SFS	Test	0.357	0.929	0.846	0.833	0.857	0.833
PCA + Bayes	Test	0.827	0.857	0.846	0.833	0.857	0.833

En test, SFS obtiene el mayor AUC y por tanto ordena mejor los casos según su probabilidad, pero la exactitud es idéntica para las tres alternativas: 11 de 13 imágenes. El conjunto de test es pequeño, por lo que una sola imagen cambia la exactitud en aproximadamente 7.7 puntos porcentuales.




Figura 4: Curvas ROC y AUC en test. El umbral operativo no se optimiza usando esta figura; fue fijado previamente en validación.

7. PCA + Bayes

PCA se ajusta sobre las seis variables estandarizadas usando únicamente entrenamiento. La cantidad de componentes se fija como el menor número que alcanza 95 % de varianza acumulada. Los valores obtenidos son:

Cuadro 7: PCA ajustado sobre entrenamiento.

Componente	Autovalor	Varianza individual	Acumulada
PC1	3.532	57.225 %	57.225 %
PC2	1.892	30.663 %	87.888 %
PC3	0.449	7.271 %	95.158 %
PC4	0.249	4.040 %	99.198 %
PC5	0.039	0.635 %	99.833 %
PC6	0.010	0.167 %	100.000 %

Se usan tres componentes porque son suficientes para superar el 95 % sin conservar las seis coordenadas originales. El clasificador GaussianNB se entrena sobre $[PC1, PC2, PC3]$ y se evalúa con el mismo umbral de Youden que las alternativas anteriores. En este experimento PCA no mejora la exactitud frente a la selección de variables, y su AUC de test (0.857) queda por debajo de SFS (0.929).




Figura 5: Varianza individual y acumulada. La línea horizontal marca el 95 % usado para elegir tres componentes.

8. Relación entre segmentación y clasificación

La calidad de la máscara es una fuente directa de error en las características: si la máscara incluye hojas, plato o madera, los promedios RGB/HSV dejan de representar solo al fruto. Para cuantificarlo se usa el clasificador de mejor AUC, Bayes + SFS, y se compara Jaccard RB por imagen en el test.

Cuadro 8: Análisis integrado en test.

Cantidad	Valor
Jaccard RB medio en desarrollo	0.560
Jaccard RB medio en test	0.465
Jaccard medio cuando la clasificación es correcta	0.538
Jaccard medio cuando la clasificación falla	0.068
Correlación de Spearman entre Jaccard y acierto	0.627
Valor p exploratorio	0.0219

Los errores de clasificación se concentran en imágenes con máscaras muy deficientes, lo que respalda que la segmentación afecta el desempeño posterior. La correlación debe interpretarse con cautela: solo hay 13 imágenes de test y la variable de acierto es binaria. El resultado no prueba causalidad, pero sí identifica una limitación operativa clara del sistema.

9. Respuestas a las preguntas centrales

1. **Mejor combinación RGB:** RB, seleccionada por el mayor Jaccard medio de desarrollo (0.560).
2. **Razón:** R y B combinan contraste cromático y de luminancia útil frente a fondos que se confunden con un solo canal; la diferencia es pequeña y depende de la escena.
3. **Características discriminantes:** R alto en maduros, G alto en inmaduros y H desplazado entre ambas clases; S también es útil según SFS.

4. **SFS:** $[G, R, B, S]$. Coincide con la selección exploratoria en R/G, pero añade B/S para absorber variación de iluminación y saturación.
5. **Mejor clasificador:** Bayes + SFS por AUC de test (0.929); la exactitud de test queda empatada en 0.846.
6. **Punto de operación:** índice de Youden, elegido para equilibrar sensibilidad y especificidad sin costos de error especificados.
7. **Número de componentes:** tres, porque la varianza acumulada alcanza 95.158% en PC3.
8. **¿PCA mejora?:** no en exactitud; obtiene 0.846, igual que las selecciones, y AUC menor que SFS.
9. **Efecto de segmentación:** las imágenes correctas tienen Jaccard medio 0.538 y las incorrectas 0.068; la contaminación del fruto deteriora las características y la decisión posterior.

10. Conclusiones y limitaciones

Se implementó el flujo solicitado de extremo a extremo y se respetó la separación por imagen y el aislamiento del test. La evidencia favorece RB para segmentación y SFS para clasificación cuando se prioriza AUC. La inspección visual y los estadísticos explican la utilidad de R, G y H, mientras que SFS detecta que B y S aportan información complementaria. PCA logra una representación compacta, pero no mejora el clasificador en esta partición.

Las conclusiones deben considerarse exploratorias. El conjunto tiene solo 62 imágenes, resoluciones y contextos muy variados, y el test contiene 13 imágenes. Además, K-Means con dos clusters y características RGB globales no modela explícitamente textura, bordes ni múltiples objetos. Un siguiente desarrollo podría incorporar postprocesamiento morfológico, más clusters, características espaciales, validación cruzada repetida o una segmentación supervisada, manteniendo la misma separación estricta del test.

Reproducibilidad

El código ejecutable está en `tomato_project.py`. Desde el directorio del proyecto se puede regenerar el conjunto de resultados con:

```
python -X utf8 tomato_project.py
pdflatex -interaction=nonstopmode -halt-on-error report.tex
pdflatex -interaction=nonstopmode -halt-on-error report.tex
```

El primer comando genera las tablas CSV, el resumen JSON y las figuras en `results/`. Los comandos LaTeX generan este informe a partir de esos artefactos.