

Proyecto 1: Segmentación y clasificación del estado de madurez de tomates

Alexa Galeano y Victor Sepulveda
INFO1185 Inteligencia Artificial

Septiembre 2026

Resumen

Se construye un sistema reproducible que segmenta tomates con K-Means y clasifica su madurez con clasificadores bayesianos gaussianos cuya regla de decisión es una razón de verosimilitudes. Tras eliminar 2 imágenes duplicadas quedan 60 imágenes (31 maduras, 29 inmaduras), divididas por imagen en 36/12/12 con semilla 20260913. De las siete combinaciones de canales, RB obtuvo el mayor Jaccard medio de desarrollo (0.568; 0.606 con post-procesado morfológico), aunque las diferencias entre combinaciones son pequeñas frente a la variabilidad entre imágenes. Con descriptores de color del fruto segmentado (incluyendo el tono como media *circular* y la coordenada a^* de CIELAB), las tres estrategias (selección por análisis: $\bar{H}$, $\bar{G}$, $\bar{R}$; SFS: $\bar{H}$, $\bar{S}$, $\bar{V}$; PCA con 3 componentes) clasifican sin errores el test de la partición principal. La unidad de análisis es la región de tomate de cada imagen (una etiqueta por imagen), no cada fruto individual. Como un test de 12 imágenes no permite distinguirlas, se complementa con intervalos bootstrap y un estudio exploratorio en 30 particiones adicionales, y se cuantifica cómo la calidad de la segmentación afecta a la clasificación.

Índice

1. Problema, objetivo y metodología	3
2. Datos y protocolo experimental	3
3. Análisis exploratorio	4
4. Segmentación mediante K-Means	5
4.1. Configuración	5
4.2. Comparación de las siete combinaciones	6
5. Extracción de características del fruto	7
6. Selección de características	8
6.1. Selección basada en el análisis exploratorio	8
6.2. Selección secuencial hacia adelante (SFS)	9
7. Clasificador bayesiano y regla de decisión	10
8. PCA + Bayes	12

9. Comparación de las tres estrategias	13
10.Relación entre segmentación y clasificación	14
11.Respuestas a las preguntas del proyecto	16
12.Conclusiones y limitaciones	16

1. Problema, objetivo y metodología

El objetivo es decidir si un tomate está *maduro* (clase positiva, ω_1) o *inmaduro* (ω_0) a partir de una imagen RGB, usando solo los píxeles que un algoritmo no supervisado identifica como fruto. El flujo completo es:

Imagen $\rightarrow$ K-Means ($k=2$) sobre R, G, B, RG, RB, GB, RGB $\rightarrow$ elección automática del cluster fruto $\rightarrow$ Jaccard vs. referencia $\rightarrow$ mejor combinación $\rightarrow$ post-procesado $\rightarrow$ $\mathbf{x} = [\bar{R}, \bar{G}, \bar{B}, \bar{H}, \bar{S}, \bar{V}, \bar{a}^*, \bar{b}^*] \rightarrow \{\text{selección por análisis} \mid \text{SFS} \mid \text{PCA}\} \rightarrow$ Bayes gaussiano $\rightarrow \ln \Lambda(\mathbf{x}) \geq \ln \theta^*$ (Youden en validación) $\rightarrow$ test

Regla de oro contra la fuga de información. Cada decisión se toma con el conjunto permitido: la combinación de canales y el post-procesado con desarrollo (entrenamiento + validación, sin ajustar parámetros); la selección de características, SFS, la estandarización y PCA con entrenamiento; el umbral con validación. El test no interviene en ninguna decisión: se evalúa con el mismo modelo que produjo las puntuaciones de validación. Los análisis complementarios (ablación de la máscara, particiones repetidas) también evalúan imágenes de test, pero están declarados como tales y no modifican el sistema.

2. Datos y protocolo experimental

El conjunto contiene las carpetas **ripe** y **unripe**, cada una con **images** y **masks**; cada imagen tiene su máscara binaria (valores 0/255) del mismo tamaño. Las resoluciones son muy heterogéneas (de 250×200 a 7792×5200 píxeles) y dos imágenes son RGBA (se descarta el canal alfa). La etiqueta se toma de la carpeta: el archivo `ripped_tomato_10.jpeg` está en **unripe** pese a su nombre; se verificó visualmente que contiene tomates verdes.

Duplicados. Un control por hash MD5 detectó 2 pares de imágenes idénticas (Tabla 1). Sin eliminarlas, una copia puede quedar en entrenamiento y la otra en validación/test, lo que infla artificialmente las métricas. Se conserva una copia de cada par: el experimento usa 60 imágenes.

Cuadro 1: Duplicados eliminados.

Eliminada	Se conserva	Clase
<code>unripped_tomato_48.jpeg</code>	<code>unripped_tomato_4.jpeg</code>	Inmaduro
<code>unripped_tomato_7.jpeg</code>	<code>unripped_tomato_61.jpeg</code>	Inmaduro

Cuadro 2: Partición estratificada por imagen.

Clase	Entrenamiento	Validación	Test	Total
Maduro	19	6	6	31
Inmaduro	17	6	6	29
Total	36	12	12	60
Porcentaje	60.0 %	20.0 %	20.0 %	100 %

Preprocesamiento. Cada imagen y su máscara se reducen conservando la proporción hasta un lado máximo de 256 píxeles (interpolación por área para la imagen, vecino más cercano para la máscara). Esto iguala el costo por imagen y evita que las imágenes grandes dominen. **Partición.** `train_test_split` estratificado en dos etapas con tamaños enteros $\text{round}(0.2n)$, semilla 20260913 (Tabla 2).




Figura 1: Ejemplos de entrenamiento con sus máscaras de referencia. Hay fondos simples (blanco) y complejos (follaje, platos, madera) y varios frutos por imagen.

3. Análisis exploratorio

Usando las máscaras de referencia de las imágenes de *entrenamiento* se muestrean hasta 3000 píxeles de fruto y 3000 de fondo por imagen (muestreo balanceado, para que las imágenes grandes o con mucho fondo no dominen). Se analizan R, G, B, HSV y CIELAB.

Tono circular. H es un ángulo: el rojo está a ambos lados de $0^\circ/360^\circ$. Un promedio aritmético de 5° y 355° da 180° (cian), un error grave justamente para tomates rojos. Por eso H se expresa en $(-180^\circ, 180^\circ]$ y se promedia con la media circular $\bar{H} = \text{atan2}(\frac{1}{n} \sum \sin h_i, \frac{1}{n} \sum \cos h_i)$.




Figura 2: Fruto vs. fondo (entrenamiento). El fruto es más saturado (S) y tiene B más bajo; el fondo es muy variable, por lo que ningún canal aislado lo separa perfectamente.




Figura 3: Píxeles de fruto: maduro vs. inmaduro. H y a^* son prácticamente bimodales por clase; R y G se desplazan en sentidos opuestos; b^* y V casi se superponen.

Cuadro 3: Medias de píxel por clase y región (entrenamiento; H media circular en grados).

Clase	Región	R	G	B	H	S	V	a^*	b^*
Maduro	fruto	194.0	75.3	45.4	12.6	0.790	0.763	42.9	42.4
Maduro	fondo	156.5	151.4	126.3	39.9	0.361	0.660	-1.2	14.8
Inmaduro	fruto	144.7	171.4	74.4	78.6	0.593	0.673	-23.2	44.4
Inmaduro	fondo	177.8	179.3	162.2	29.6	0.218	0.724	-3.1	9.2

Observaciones. (i) Fruto vs. fondo: el fruto tiene mayor saturación y menor B que el fondo en ambas clases; el tomate inmaduro, sin embargo, comparte tono verde con el follaje, lo que anticipa errores de segmentación en escenas de planta. (ii) Maduro vs. inmaduro: el tono se concentra cerca de 0° – 20° en maduros y cerca de 80° en inmaduros; a^* (eje verde-rojo) es negativo en inmaduros y positivo en maduros; R es mayor y G menor en maduros. Estas observaciones guían la selección de la Sección 6.1.

4. Segmentación mediante K-Means

4.1. Configuración

- **Número de clusters:** $k = 2$ (fruto y fondo), un K-Means independiente por imagen y por combinación de canales (sin estandarizar: los tres canales comparten escala).
- **Inicialización:** k-means++, 10 reinicios; se conserva la solución de menor inercia.
- **Convergencia:** parada cuando el desplazamiento de centroides es menor que 10^{-4} (tolerancia relativa) o a las 300 iteraciones. Ninguna ejecución llegó al máximo (Tabla 5, última columna).
- **Semilla:** 20260913 (también para muestrear 12000 píxeles con los que se ajustan los centroides; luego se asignan todos los píxeles).

¿Qué cluster es el fruto? Las etiquetas de K-Means son arbitrarias. Sin mirar la máscara de referencia, para cada cluster c se calcula un puntaje de objeto

$$s_c = 0.10 \text{coh}_c + 0.15 \text{cent}_c + 0.30 \bar{S}_c + 0.50 \bar{V}_c + 0.10 e^{-((A_c - 0.38)/0.32)^2} - 0.10 \text{borde}_c,$$

donde coh es la fracción del cluster en su componente conexa mayor, cent la cercanía de esa componente al centro, $\bar{S}_c, \bar{V}_c$ la saturación y el brillo medios, A_c el área relativa y borde la fracción del

marco de la imagen que ocupa el cluster. Se elige $\arg \max_c s_c$. La referencia se usa *solo* para calcular Jaccard, $J(A, B) = |A \cap B| / |A \cup B|$. Para justificar la regla se comparó en desarrollo con dos reglas simples y con un *oráculo* que elige el cluster con mayor Jaccard (cota superior alcanzable con esos clusters). El puntaje de objeto es la mejor regla automática en 6 de las 7 combinaciones (en B la supera levemente la máxima saturación) y queda a 0.01 del oráculo en RB (a lo más 0.033, en G; Tabla 4): el límite principal lo pone K-Means con $k = 2$, no la regla. *Limitación*: los pesos del puntaje y el prior de área son heurísticos (fijados a priori a mano, no ajustados por optimización ni con las máscaras de test); la tabla muestra su desempeño, pero no se exploró una regla aprendida.

Cuadro 4: Jaccard medio en desarrollo según la regla de elección del cluster.

Canales	Puntaje objeto	Mín. borde	Máx. saturación	Oráculo
R	0.528	0.504	0.416	0.541
G	0.510	0.470	0.477	0.543
B	0.543	0.472	0.545	0.559
RG	0.557	0.550	0.471	0.575
RB	0.568	0.552	0.494	0.578
GB	0.538	0.496	0.516	0.565
RGB	0.552	0.535	0.499	0.574

4.2. Comparación de las siete combinaciones

Cuadro 5: Jaccard por combinación (media o media $\pm$ DE entre imágenes). La selección usa solo la columna Desarrollo; Test se informa como evaluación final.

Canales	Entr.	Valid.	Desarrollo	+Post	Oráculo	Test	Test +Post	Iter. (media/máx)
R	0.555	0.447	0.528 $\pm$ 0.247	0.571	0.541	0.468 $\pm$ 0.228	0.475	6.1 / 28
G	0.508	0.518	0.510 $\pm$ 0.263	0.535	0.543	0.402 $\pm$ 0.264	0.402	4.9 / 11
B	0.560	0.492	0.543 $\pm$ 0.304	0.583	0.559	0.392 $\pm$ 0.288	0.406	5.5 / 13
RG	0.565	0.532	0.557 $\pm$ 0.258	0.593	0.575	0.471 $\pm$ 0.254	0.472	6.1 / 15
RB	0.585	0.514	0.568 $\pm$ 0.278	0.606	0.578	0.460 $\pm$ 0.291	0.457	5.4 / 14
GB	0.544	0.518	0.538 $\pm$ 0.301	0.577	0.565	0.376 $\pm$ 0.294	0.379	5.2 / 12
RGB	0.561	0.525	0.552 $\pm$ 0.285	0.589	0.574	0.443 $\pm$ 0.266	0.448	6.0 / 24




Figura 4: Jaccard medio en desarrollo (barras de error: DE entre imágenes).

Resultado. RB obtiene el mayor Jaccard de desarrollo (0.568), seguido de RG (0.557); la peor es G (0.510). Las combinaciones que incluyen R son las mejores: R separa el tomate rojo de fondos verdes

y B separa objetos saturados (B bajo) de fondos claros/grises (B alto, Figura 2). G en solitario es la peor porque el tomate inmaduro y el follaje tienen G parecido. **Análisis crítico:** la DE entre imágenes (≈ 0.28) es mucho mayor que la diferencia entre combinaciones (≈ 0.06 entre la mejor y la peor), por lo que el ranking es débil; y el Jaccard cae en test (0.460 sin post-procesado; 0.457 con la máscara final que usa el sistema), reflejo de escenas difíciles en esa muestra de 12 imágenes. K-Means con $k = 2$ usa solo color: falla cuando el fondo tiene un color parecido al fruto (follaje con tomates verdes) o cuando el fondo es bimodal (plato blanco + mesa), ya que entonces los dos clusters separan *dos fondos* y el tomate queda repartido.

Post-procesado. Apertura y cierre (elipse 5×5), relleno de huecos y eliminación de componentes $< 1\%$ de la imagen elevan el Jaccard de desarrollo de RB a 0.606 (mejora la media de desarrollo en 7 de las 7 combinaciones; en test, para RB, pasa de 0.460 a 0.457), por lo que se usa para extraer características (decisión tomada en desarrollo: sí).




Figura 5: Peor, mediana y mejor imagen de desarrollo para RB. El peor caso es un fallo típico: el cluster elegido es el follaje brillante y los tomates quedan fuera.




Figura 6: Las siete combinaciones sobre dos imágenes de desarrollo.

5. Extracción de características del fruto

Con la máscara final de RB cada fruto se representa por $\mathbf{x} = [\bar{R}, \bar{G}, \bar{B}, \bar{H}, \bar{S}, \bar{V}, \bar{a}^*, \bar{b}^*]$, promedios calculados solo sobre píxeles segmentados:

- $\bar{R}, \bar{G}, \bar{B}$ (0–255): mínimo exigido; la madurez desplaza energía de G a R.
- $\bar{H}$ (media circular, grados), $\bar{S}, \bar{V}$ ([0, 1]): separan cromaticidad (H, S) de brillo (V), por lo que H es menos sensible a la iluminación que RGB.
- $\bar{a}^*, \bar{b}^*$ (CIELAB): $\bar{a}^*$ es el eje verde↔rojo, el índice colorimétrico clásico de madurez de tomate; $\bar{b}^*$ (azul↔amarillo) se incluye como control.

6. Selección de características

6.1. Selección basada en el análisis exploratorio

Sobre las imágenes de entrenamiento (con máscara K-Means, igual que en operación) se mide la separación de cada descriptor con la d de Cohen y el AUC univariado (Tabla 6, Figura 7). Regla: ordenar por $|d|$ y aceptar un descriptor solo si $|r| \leq 0.85$ con los ya elegidos, hasta 3 descriptores (con 36 imágenes de entrenamiento se busca un modelo pequeño). La redundancia importa porque Bayes *ingenuo* multiplica verosimilitudes como si fueran independientes: dos variables casi colineales cuentan dos veces la misma evidencia y producen probabilidades sobreconfiadas.

Cuadro 6: Separabilidad en entrenamiento (media $\pm$ DE por clase).

Descriptor	Maduro	Inmaduro	d de Cohen	AUC univ.	Selección
$\bar{R}$	186.9 $\pm$ 30.3	143.9 $\pm$ 20.3	1.65	0.889	✓
$\bar{G}$	102.2 $\pm$ 46.0	167.8 $\pm$ 24.9	-1.75	0.885	✓
$\bar{B}$	69.1 $\pm$ 41.4	81.3 $\pm$ 26.9	-0.35	0.641	
$\bar{H}$	19.2 $\pm$ 16.4	80.0 $\pm$ 13.3	-4.04	0.981	✓
$\bar{S}$	0.651 $\pm$ 0.180	0.544 $\pm$ 0.135	0.67	0.697	
$\bar{V}$	0.750 $\pm$ 0.116	0.666 $\pm$ 0.088	0.80	0.755	
$\bar{a}^*$	29.0 $\pm$ 19.5	-20.7 $\pm$ 7.5	3.28	0.957	
$\bar{b}^*$	35.6 $\pm$ 12.4	39.9 $\pm$ 10.9	-0.36	0.616	




Figura 7: Descriptores del fruto segmentado en entrenamiento.

Seleccionadas: $\bar{H}, \bar{G}, \bar{R}$. $\bar{H}$ es la variable más separable (maduros cerca de 20°, inmaduros cerca de 80°). $\bar{a}^*$ es la segunda pero se descarta por su correlación con $\bar{H}$ ($|r| = 0.92$, Figura 8): aporta casi la misma información. $\bar{G}$ (alto en inmaduros) y $\bar{R}$ (alto en maduros) completan el subconjunto con

información de intensidad por canal no redundante con el tono. $\bar{B}$, $\bar{b}^*$, $\bar{S}$ y $\bar{V}$ tienen $|d| < 1$: dependen más de la iluminación y del fondo que de la madurez.





Figura 8: Correlación entre descriptores (entrenamiento).

6.2. Selección secuencial hacia adelante (SFS)

SFS tipo *wrapper*: se parte del conjunto vacío y en cada paso se añade la variable que maximiza el AUC medio de validación cruzada estratificada 5×10 (repetida) del mismo clasificador Bayes, usando solo entrenamiento. La búsqueda se completa hasta las 8 variables para ver la traza entera; el subconjunto final es el más pequeño cuyo AUC queda a menos de 10^{-3} del mejor (parsimonia cuando el criterio se satura).

Cuadro 7: Traza de SFS.

Paso	Se añade	AUC CV (media $\pm$ DE)	Tamaño elegido
1	$\bar{H}$	0.981 ± 0.047	
2	$\bar{S}$	0.987 ± 0.040	
3	$\bar{V}$	0.988 ± 0.039	✓
4	$\bar{B}$	0.988 ± 0.039	
5	$\bar{R}$	0.987 ± 0.036	
6	$\bar{G}$	0.985 ± 0.041	
7	$\bar{a}^*$	0.983 ± 0.044	
8	$\bar{b}^*$	0.980 ± 0.046	



Seleccionadas: $\bar{H}$, $\bar{S}$, $\bar{V}$. Coincide con la selección por análisis en $\bar{H}$ (primera variable elegida, confirmando el análisis), pero reemplaza $\bar{G}$ y $\bar{R}$ por $\bar{S}$ y $\bar{V}$. Razones de la diferencia: (i) SFS optimiza el desempeño conjunto, no la separación individual; $\bar{S}$ y $\bar{V}$ son débiles solas ($|d| < 1$), pero separan saturación y brillo del tono y pueden aportar cuando la máscara incluye fondo (hipótesis coherente con la Figura 2); (ii) SFS no considera redundancia explícitamente, solo si el AUC mejora; (iii) el criterio está saturado ($AUC \approx 0.98$) y la DE entre pliegues (≈ 0.04) supera las diferencias entre subconjuntos, por lo que la elección después de $\bar{H}$ es inestable (ver la frecuencia de subconjuntos en las particiones repetidas, Sección 9). Esta sensibilidad también se observa entre entornos: diferencias menores a un nivel de gris al leer y redimensionar las imágenes bastan para que SFS elija otro subconjunto con el mismo desempeño en test (Sección Reproducibilidad).

7. Clasificador bayesiano y regla de decisión

Modelo. Bayes gaussiano ingenuo: $p(\mathbf{x} | \omega_k) = \prod_j \mathcal{N}(x_j; \mu_{kj}, \sigma_{kj}^2)$, con medias y varianzas estimadas por máxima verosimilitud en entrenamiento (suavizado de varianza 10^{-9} $\max_j \sigma_j^2$). **Regla por razón de verosimilitudes:**

$$\ln \Lambda(\mathbf{x}) = \ln p(\mathbf{x} | \omega_1) - \ln p(\mathbf{x} | \omega_0) \begin{matrix} \text{maduro} \\ \geq \\ \text{inmaduro} \end{matrix} \ln \theta.$$

La regla de Bayes de mínimo error corresponde a $\theta = P(\omega_0)/P(\omega_1)$ (con costos, $\theta = \frac{(C_{10}-C_{00})P(\omega_0)}{(C_{01}-C_{11})P(\omega_1)}$); variar θ recorre la curva ROC. Bayes ingenuo es prácticamente invariante a reescalar cada variable (salvo el pequeño suavizado de varianza de **GaussianNB**), así que las variables seleccionadas no se estandarizan (sí antes de PCA).

Punto de operación: índice de Youden. $J(\theta) = \text{sens}(\theta) + \text{espec}(\theta) - 1$ se maximiza en validación. Se elige porque no hay costos de error definidos en el enunciado, las clases están balanceadas y J pondera igual ambos errores (equivale al punto de la ROC más alejado de la diagonal). Los umbrales candidatos son los puntos medios entre puntuaciones consecutivas de validación, y si varios empatan se toma el central, para no dejar la frontera pegada a una muestra. *El mismo modelo* (ajustado en entrenamiento) produce las puntuaciones de validación y de test, de modo que el umbral se aplica a la función para la que fue elegido.




Figura 9: Sensibilidad, especificidad y exactitud en validación en función de $\ln \theta$ (eje simétrico logarítmico). Línea discontinua: umbral de Youden.

Cuadro 8: Puntos de operación seleccionados en validación.

Estrategia	Entradas	$\ln \theta^*$	J en validación	Umbrales empatados
Bayes + análisis	$\bar{H}, \bar{G}, \bar{R}$	7.46	1.000	1
Bayes + SFS	$\bar{H}, \bar{S}, \bar{V}$	4.50	1.000	1
PCA + Bayes	PC1, PC2, PC3	1.79	1.000	1

Los tres umbrales de Youden son mayores que $\ln \theta = 0$. Con $\theta = 1$ habría errores de validación en análisis (1 FP, 0 FN), SFS (1 FP, 0 FN); PCA no tendría errores. Como la validación es separable, Youden alcanza $J = 1$ en todo un intervalo de umbrales y el elegido es el punto medio de ese hueco, no un valor único. Un umbral positivo no prueba por sí solo sobreconfianza, pero es compatible con el supuesto ingenuo (variables correlacionadas pueden exagerar $|\ln \Lambda|$) y muestra por qué el umbral se calibra en validación.

Cuadro 9: Métricas con el umbral de Youden (positivo = maduro).

Estrategia	Conjunto	$\ln \theta^*$	AUC	Exact.	Sens.	Espec.	F1	VP/FN/VN/FP
Bayes + análisis	Validación	7.46	1.000	1.000	1.000	1.000	1.000	6/0/6/0
Bayes + SFS	Validación	4.50	1.000	1.000	1.000	1.000	1.000	6/0/6/0
PCA + Bayes	Validación	1.79	1.000	1.000	1.000	1.000	1.000	6/0/6/0
Bayes + análisis	Test	7.46	1.000	1.000	1.000	1.000	1.000	6/0/6/0
Bayes + SFS	Test	4.50	1.000	1.000	1.000	1.000	1.000	6/0/6/0
PCA + Bayes	Test	1.79	1.000	1.000	1.000	1.000	1.000	6/0/6/0




Figura 10: Curvas ROC con el punto de operación (círculo). Las tres curvas coinciden en el vértice (0,1).




Figura 11: Matrices de confusión en test.

Cuadro 10: IC bootstrap estratificado al 95 % en test (2000 remuestreos).

Estrategia	AUC	Exactitud	Sensibilidad	Especificidad
Bayes + análisis	[1.00, 1.00]	[1.00, 1.00]	[1.00, 1.00]	[1.00, 1.00]
Bayes + SFS	[1.00, 1.00]	[1.00, 1.00]	[1.00, 1.00]	[1.00, 1.00]
PCA + Bayes	[1.00, 1.00]	[1.00, 1.00]	[1.00, 1.00]	[1.00, 1.00]

Con 12 imágenes y cero errores el bootstrap degenera en [1,1]: *no* indica certeza, sino que no hay variabilidad que remuestrear. Un test de 12 casos sin errores es compatible con una exactitud real bastante menor (la cota exacta de Clopper–Pearson al 95 % es ≈ 0.74). Por eso la comparación se complementa en la Sección 9.

8. PCA + Bayes

PCA se ajusta en entrenamiento sobre las 8 variables estandarizadas (z -score con media y DE de entrenamiento), porque sin estandarizar las variables en 0–255 dominarían la varianza. Se elige el menor p que alcanza el 95 % de varianza acumulada: $p = 3$ (97.9 %). Además hay un codo claro: PC4 explica menos del 2 % y su valor propio es muy inferior a 1 (criterio de Kaiser), es decir, aporta menos que una variable original.

Cuadro 11: Valores propios.

Componente	Valor propio λ	Varianza	Acumulada
PC1	3.715	45.14 %	45.14 %
PC2	2.801	34.04 %	79.18 %
PC3	1.536	18.67 %	97.85 %
PC4	0.121	1.48 %	99.33 %
PC5	0.038	0.46 %	99.79 %
PC6	0.013	0.15 %	99.94 %
PC7	0.004	0.05 %	99.99 %
PC8	0.001	0.01 %	100.00 %





Figura 12: Cargas. PC1 es el eje de madurez (a^* y S positivos; H, G y B negativos); PC2 combina brillo y desaturación (R, B, V frente a S y b^*); PC3 es un eje amarillo–brillo (b^* , V). Solo PC1 está alineada con la clase: PCA maximiza varianza, no separación.

Las componentes están decorrelacionadas globalmente en entrenamiento, pero eso no garantiza independencia ni decorrelación dentro de cada clase, que es lo que asume Bayes ingenuo (por ejemplo, PC1 y PC2 siguen correlacionadas dentro de cada clase). Como información complementaria (*no* usada para elegir p), el desempeño en validación ya es máximo desde $p = 1$:

Cuadro 12: Validación según p (solo diagnóstico).

p	Var. acumulada	AUC valid.	Exact. valid.
1	45.1 %	1.000	1.000
2	79.2 %	1.000	1.000
3	97.9 %	1.000	1.000
4	99.3 %	1.000	1.000
5	99.8 %	1.000	1.000
6	99.9 %	1.000	1.000
7	100.0 %	1.000	1.000
8	100.0 %	0.972	0.917

9. Comparación de las tres estrategias

En la partición principal las tres estrategias empatan con desempeño perfecto (Tabla 9), por lo que ese test no permite ordenarlas. Para comparar bajo las mismas condiciones con más evidencia, se repitió el protocolo completo en 30 particiones 60/20/20 adicionales (semillas distintas): elección de la combinación de canales y del post-procesado con el Jaccard de desarrollo de cada partición, selección por análisis, SFS, PCA, umbral de Youden y test. La combinación elegida fue RB en 28, RG en 2 particiones, con post-procesado en 30. (Los K-Means por imagen no dependen de la partición, por lo que se calculan una sola vez.) Las particiones comparten imágenes, así que no son muestras independientes: sirven para medir estabilidad, no para pruebas de significancia. Es un estudio exploratorio posterior: las 12 imágenes del test principal reaparecen en entrenamiento o validación de otras particiones, por lo que *no* se usa para elegir el sistema ni para desempatar el test principal.

Cuadro 13: Test en 30 particiones (media $\pm$ DE). Errores: FP+FN acumulados en 360 predicciones. Corrige / introduce: errores del sistema (K-Means) que la variante corrige y errores nuevos que genera, imagen por imagen. Las variantes se explican en la Sección 10.

Variante	Estrategia	AUC test	Exactitud test	Errores	Corrige / introduce
K-Means (sistema)	Bayes + análisis	0.989 ± 0.033	0.967 ± 0.042	12	0 / 0
K-Means (sistema)	Bayes + SFS	0.993 ± 0.021	0.969 ± 0.041	11	0 / 0
K-Means (sistema)	PCA + Bayes	0.978 ± 0.049	0.964 ± 0.061	13	0 / 0
Ideal solo en test, mismo modelo	Bayes + análisis	1.000 ± 0.000	0.997 ± 0.015	1	12 / 1
Ideal solo en test, mismo modelo	Bayes + SFS	1.000 ± 0.000	0.994 ± 0.021	2	9 / 0
Ideal solo en test, mismo modelo	PCA + Bayes	1.000 ± 0.000	0.978 ± 0.043	8	11 / 6
Ideal, diseño fijo	Bayes + análisis	1.000 ± 0.000	1.000 ± 0.000	0	12 / 0
Ideal, diseño fijo	Bayes + SFS	1.000 ± 0.000	1.000 ± 0.000	0	11 / 0
Ideal, diseño fijo	PCA + Bayes	1.000 ± 0.000	1.000 ± 0.000	0	13 / 0
Ideal, rediseño completo	Bayes + análisis	1.000 ± 0.000	1.000 ± 0.000	0	12 / 0
Ideal, rediseño completo	Bayes + SFS	1.000 ± 0.000	0.969 ± 0.056	11	11 / 11
Ideal, rediseño completo	PCA + Bayes	1.000 ± 0.000	1.000 ± 0.000	0	13 / 0
K-Means, $\bar{H}$ aritmético	Bayes + análisis	0.978 ± 0.051	0.958 ± 0.061	15	4 / 7
K-Means, $\bar{H}$ aritmético	Bayes + SFS	0.976 ± 0.051	0.964 ± 0.068	13	5 / 7
K-Means, $\bar{H}$ aritmético	PCA + Bayes	0.955 ± 0.072	0.886 ± 0.092	41	3 / 31




Figura 13: Exactitud media de test ($\pm$ DE) y errores acumulados (FP+FN) en las particiones repetidas, para el sistema y las variantes de la ablación.

Lectura. Con máscaras K-Means, las exactitudes medias son Bayes + SFS 0.969 ± 0.041 (11 errores en 360 predicciones), Bayes + análisis 0.967 ± 0.042 (12 errores) y PCA + Bayes 0.964 ± 0.061 (13

errores, sobre todo maduros clasificados como inmaduros). Comparando partición por partición, PCA gana/empata/pierde 4/22/4 veces frente a análisis y 5/21/4 frente a SFS. Las diferencias son de pocos errores y quedan dentro de la variabilidad entre particiones: en este estudio *no* se puede ordenar a las tres estrategias.

Estabilidad de la selección (conjuntos contados sin importar el orden). La regla por análisis produjo 6 subconjuntos distintos; el más frecuente fue $\bar{R}$, $\bar{S}$, $\bar{a}^*$ (14 de 30) y el de la partición principal apareció 12 veces; las alternativas suelen cambiar $\bar{H}$ por $\bar{a}^*$, su sustituto casi colineal. SFS produjo 11 subconjuntos distintos; incluyó $\bar{H}$ en 30 particiones y se quedó *solo* con $\bar{H}$ en 11. Un indicio adicional: si toda la selección se rehace con máscaras de referencia, SFS es la única estrategia con errores (11, frente a 0 de análisis y 0 de PCA), mientras que con la selección hecha sobre K-Means y máscaras ideales no comete ninguno (0, Sección 10). Con 36 imágenes y un criterio saturado, una hipótesis compatible es que el *wrapper* sobreajuste la propia selección; estos datos no aíslan ese mecanismo. La regla guiada por el análisis resultó menos inestable, aunque tampoco repite siempre el mismo subconjunto.

¿Por qué PCA no mejora? PCA es no supervisado: conserva direcciones de máxima varianza, y en este problema buena parte de la varianza se debe al brillo y al fondo contaminante (PC2, PC3), no a la madurez. Además, al proyectar las 8 variables, PCA reintroduce $\bar{B}$, $\bar{V}$ y $\bar{b}^*$, que son las más afectadas por errores de máscara.

10. Relación entre segmentación y clasificación

Para estudiar el efecto de la segmentación sin mezclarlo con otros cambios, se comparan variantes que modifican *una sola cosa* respecto del sistema (máscara K-Means final):

- **Ideal solo en test, mismo modelo:** mismas variables, mismo modelo y mismo umbral; únicamente los descriptores de test se extraen con la máscara de referencia. Aísla el efecto de la segmentación en el momento de clasificar.
- **Ideal, diseño fijo:** mismas variables o mismo número de componentes; el modelo y el umbral se reajustan con descriptores de máscara de referencia en entrenamiento y validación. Aísla la calidad de la máscara con la selección fija.
- **K-Means sin post-procesado, diseño fijo:** igual, con la máscara K-Means cruda.
- **Ideal, rediseño completo** (solo como referencia): se repite toda la selección con máscaras de referencia. *No* es una comparación controlada, porque cambian a la vez la máscara, las variables, el modelo y el umbral.

Para las variantes controladas se cuentan, imagen por imagen, los errores del sistema que la variante corrige y los que introduce.

Cuadro 14: AUC / exactitud en test (partición principal) según la variante.

Variante	Bayes + análisis	Bayes + SFS	PCA + Bayes
K-Means (sistema)	1.000 / 1.000	1.000 / 1.000	1.000 / 1.000
K-Means sin post-proc., diseño fijo	1.000 / 1.000	1.000 / 1.000	1.000 / 1.000
Ideal solo en test, mismo modelo	1.000 / 1.000	1.000 / 1.000	1.000 / 1.000
Ideal, diseño fijo	1.000 / 1.000	1.000 / 1.000	1.000 / 1.000
Ideal, rediseño completo	1.000 / 1.000	1.000 / 1.000	1.000 / 1.000
K-Means, $\bar{H}$ aritmético	1.000 / 1.000	1.000 / 1.000	0.944 / 0.917




Figura 14: Izquierda: distancia estandarizada entre los descriptores con máscara K-Means y con máscara de referencia vs. Jaccard (todas las imágenes; Spearman $\rho = -0.89$, $p = 1.1e - 21$). Derecha: $\ln \Lambda$ de Bayes + análisis (estrategia con mejor AUC de validación) para las imágenes de test.

Cuadro 15: Imágenes de test ordenadas por Jaccard.

Imagen	Clase	Jaccard	Desplaz. $\mathbf{x}$	B+análisis	B+SFS	PCA+B
unripped_tomato_43.jpeg	Inmaduro	0.097	3.25	✓	✓	✓
unripped_tomato_1.jpeg	Inmaduro	0.113	5.88	✓	✓	✓
unripped_tomato_6.jpeg	Inmaduro	0.160	4.95	✓	✓	✓
ripped_tomato_97.jpeg	Maduro	0.164	5.62	✓	✓	✓
unripped_tomato_12.jpeg	Inmaduro	0.295	1.40	✓	✓	✓
unripped_tomato_65.jpeg	Inmaduro	0.453	2.70	✓	✓	✓
ripped_tomato_83.jpeg	Maduro	0.505	1.92	✓	✓	✓
ripped_tomato_52.jpeg	Maduro	0.566	2.00	✓	✓	✓
ripped_tomato_6.jpeg	Maduro	0.688	0.18	✓	✓	✓
ripped_tomato_22.jpeg	Maduro	0.753	0.67	✓	✓	✓
unripped_tomato_9.jpeg	Inmaduro	0.757	0.60	✓	✓	✓
ripped_tomato_40.jpeg	Maduro	0.936	0.30	✓	✓	✓

Mecanismo. Una máscara peor contamina los descriptores: la distancia entre $\mathbf{x}$ con máscara K-Means y con máscara de referencia muestra una asociación negativa fuerte con el Jaccard ($\rho = -0.89$).

Efecto en la clasificación. En la partición principal todas las variantes de máscara aciertan (Tabla 14; solo la ablación del tono con PCA falla), por lo que el efecto se mide en las 30 particiones (Tabla 13):

- *Ideal solo en test, mismo modelo.* Sin tocar variables, modelo ni umbral, los errores bajan de 12/11/13 (análisis/SFS/PCA) a 1/2/8. La variante corrige 12/9/11 errores e introduce 1/0/6: el modelo fue ajustado con descriptores contaminados, así que una máscara limpia en test no coincide del todo con lo aprendido; PCA es la más afectada.
- *Ideal, diseño fijo.* Con las mismas variables y reajustando modelo y umbral con máscaras ideales, las tres estrategias no cometen errores (0/0/0).

Conclusión acotada: manteniendo fija la selección de variables, reemplazar la máscara K-Means por la de referencia elimina todos los errores observados en estas particiones; por tanto, en este conjunto la segmentación es la causa dominante de los errores del sistema. No se afirma más allá de eso: las particiones comparten imágenes y la máscara de referencia es una cota ideal, no una alternativa disponible en operación. La variante de rediseño completo no se usa para esta conclusión, porque ahí cambian también las variables (SFS pasa a elegir solo $\bar{H}$ y comete 11 errores).

¿Por qué el clasificador tolera Jaccard bajos? 4 de las 12 imágenes de test tienen $J < 0.2$ y aun así se clasifican bien. El descriptor dominante es el tono medio, una magnitud cromática que

no depende del brillo; y el error típico de K-Means incluye píxeles cuyo tono es compatible con la clase (p. ej. follaje verde junto a tomates verdes). Cabe esperar que el sistema sea vulnerable cuando el fondo incluido tiene el tono de la clase contraria (tomate rojo entre hojas); es coherente con que los errores de PCA con máscaras K-Means sean sobre todo maduros clasificados como inmaduros. *Limitación:* en este conjunto el color del fondo está correlacionado con la clase, así que el sistema puede acertar en parte por la escena y no solo por el fruto; esto limita cuánto se puede generalizar el efecto de la segmentación.

Ablación del tono. Si $\bar{H}$ se calcula con media aritmética en $[0, 360)$, los tomates rojos con píxeles a ambos lados de 0° obtienen tonos espurios. En las particiones repetidas la exactitud de PCA + Bayes cae de 0.964 ± 0.061 a 0.886 ± 0.092 (41 errores), mientras que SFS (0.964 ± 0.068) y análisis (0.958 ± 0.061) caen poco, porque pueden apoyarse en $\bar{a}^*$, que no tiene discontinuidad.

11. Respuestas a las preguntas del proyecto

1. **Mejor combinación:** RB, con Jaccard medio de desarrollo 0.568 (0.606 con post-procesado), seguida de RG (0.557).
2. **Por qué:** R separa rojo de verde y B separa objetos saturados (B bajo) de fondos claros o grises (B alto); juntos cubren los dos tipos de fondo del conjunto. La ventaja es pequeña frente a la DE entre imágenes, así que es una preferencia débil.
3. **Características discriminantes (exploratorio):** tono circular $\bar{H}$ y $\bar{a}^*$ ($|d| > 3$), seguidos de $\bar{G}$ y $\bar{R}$; B, S, V y b^* discriminan poco.
4. **SFS:** $\bar{H}$, $\bar{S}$, $\bar{V}$. Coincide solo en $\bar{H}$ con la selección por análisis ($\bar{H}$, $\bar{G}$, $\bar{R}$) y cambia $\bar{G}$ y $\bar{R}$ por $\bar{S}$ y $\bar{V}$, porque optimiza el AUC conjunto con un criterio saturado y ruidoso; en las particiones repetidas eligió 11 subconjuntos distintos, con $\bar{H}$ en 30 de 30.
5. **Mejor estrategia:** en la partición principal empatan (exactitud y AUC de 1). En 30 particiones, SFS (0.969 ± 0.041) y análisis (0.967 ± 0.042) y PCA (0.964 ± 0.061) son equivalentes dentro de la variabilidad; la selección por análisis es menos inestable y más interpretable.
6. **Punto de operación:** índice de Youden en validación sobre $\ln \Lambda$, porque no hay costos definidos, las clases están balanceadas y ambos errores pesan igual.
7. **Componentes:** 3, el menor número con $\geq 95\%$ de varianza acumulada (97.9 %), coincidente con el codo y con Kaiser ($\lambda_4 \ll 1$).
8. **¿PCA mejora?** No: empata en la partición principal y en las particiones repetidas tiene una exactitud media similar (0.964 ± 0.061 ; gana/empata/pierde 4/22/4 frente a análisis). Maximiza varianza, no separación, y es la más sensible a la ablación del tono.
9. **Efecto de la segmentación:** peor Jaccard $\Rightarrow$ descriptores más desplazados ($\rho = -0.89$). Con la selección fija, usar la máscara ideal elimina los 12/11/13 errores del sistema en las 30 particiones, y usarla solo en test (mismo modelo) deja 1/2/8: la segmentación es la principal fuente de los errores observados. Aun así, 4 imágenes de test con $J < 0.2$ se clasifican bien, porque el fondo incluido suele tener un color compatible con la clase.

12. Conclusiones y limitaciones

Conclusiones. (1) K-Means con $k = 2$ segmenta de forma moderada (Jaccard ≈ 0.6 en desarrollo con RB + post-procesado) y es el eslabón débil del sistema. (2) La madurez es esencialmente un problema de tono: con $\bar{H}$ calculado como media circular, un Bayes gaussiano con 3 variables clasifica casi perfectamente. (3) En este experimento, la selección guiada por el análisis, SFS y PCA tienen desempeño equivalente; el análisis es menos inestable y más interpretable, y PCA no mejora a las otras

dos. (4) En una ablación controlada (selección fija), la máscara ideal elimina los errores observados en las particiones repetidas: la segmentación es su principal fuente en este conjunto.

Limitaciones. Conjunto pequeño (60 imágenes; test de 12), cercano al techo de desempeño, lo que impide ordenar estrategias con un único test; la ruptura de empates se apoya en particiones repetidas, que comparten imágenes y no son independientes entre sí. Los pesos del puntaje de objeto son heurísticos. El color del fondo está correlacionado con la clase, por lo que no se garantiza generalización a otras escenas. Se clasifica la región de tomate por imagen, no cada fruto. K-Means solo usa color (sin textura ni forma) y $k = 2$ falla con fondos bimodales. Bayes ingenuo ignora correlaciones y produce $\ln \Lambda$ sobreconfiados. Las imágenes se reducen a 256 píxeles, por lo que Jaccard se mide a esa resolución. **Trabajo futuro:** $k > 2$ con selección de varios clusters, características espaciales (posición, textura), Bayes con covarianza completa y un conjunto de datos mayor.

Reproducibilidad

Todo el experimento se regenera con `python -X utf8 tomato_project.py` (parámetros y semillas en `tomato/config.py`). Las tablas y los números de este informe se generan automáticamente en `results/tex/`; las interpretaciones escritas se revisaron contra la corrida entregada. Los resultados entregados se obtuvieron en Linux (Python 3.13.5) con las versiones de `requirements.txt`, y se reprodujeron idénticos en un segundo equipo Linux. Una versión previa, generada en otro entorno, difería en menos de un nivel de gris al leer y redimensionar las imágenes; esa diferencia bastó para que SFS eligiera otro subconjunto $(\bar{H}, \bar{B}, \bar{S}, \bar{R})$ con el mismo desempeño perfecto en test. K-Means se ejecuta con un único hilo OpenMP. Con varios hilos, las sumas en coma flotante de scikit-learn dependen del número de núcleos; en una prueba con 1 frente a 16 hilos, 53 de 180 ejecuciones produjeron etiquetas distintas (pequeñas diferencias bastan para cambiar qué reinicio de K-Means gana). Con un hilo los resultados son idénticos entre ejecuciones y configuraciones de hilos.