


Proyecto 1

Segmentación y clasificación del estado de madurez de tomates

K-Means · Bayes con razón de verosimilitudes · SFS · PCA



1

Problema y objetivo

Decidir si un tomate está maduro o inmaduro a partir de una imagen RGB, usando únicamente los píxeles que un método no supervisado identifica como fruto.



No supervisado

K-Means separa fruto y fondo por color; se evalúa con Jaccard contra la máscara anotada.

Supervisado

Clasificador bayesiano gaussiano sobre descriptores del fruto; umbral por Youden.

Preguntas

¿Qué canales segmentan mejor?
¿Qué variables distinguen la madurez? ¿Ayuda PCA? ¿Cuánto pesa la segmentación?

Descripción de los datos

60

imágenes útiles (31 maduras / 29 inmaduras)

2


duplicados exactos eliminados (MD5)

36/12/12

entrenamiento / validación / test

≤ 256 px

lado máximo tras reducir (anchos originales 250–7792)



Partición estratificada por imagen, semilla 20260913. Una copia duplicada estaba en entrenamiento y la otra en validación: se eliminó para evitar fuga. Fondos simples (blanco) y complejos (follaje, platos, madera); varios frutos por imagen.

Metodología general y control de fuga

Decisión	Datos usados
Combinación de canales y post-procesado	Desarrollo (entrenamiento + validación)
Selección por análisis, SFS, estandarización, PCA	Solo entrenamiento
Umbral de la razón de verosimilitudes (Youden)	Validación, con el modelo de entrenamiento
Métricas finales (AUC, exactitud, sens., espec.)	Test, una única vez
Robustez de la comparación	30 particiones 60/20/20 repetidas

Reproducible


Semilla 20260913 en partición, muestreo de píxeles, K-Means y validación cruzada. Parámetros en `tomato/config.py`.

Trazable

Las tablas y cifras del informe y de esta presentación se generan desde los resultados del código.

Análisis exploratorio: fruto vs fondo

Píxeles de entrenamiento: fruto vs fondo




Fruto: S alto, B bajo

Fondo muy variable

Tomate verde ≈ follaje

Análisis exploratorio: maduro vs inmaduro

Píxeles de fruto (máscara de referencia): maduro vs inmaduro



H y a* separan las clases; R sube y G baja

H circular: media de 5° y 355° ≠ 180°

Segmentación con K-Means

Clusters	k = 2 (fruto / fondo), un modelo por imagen y combinación
Inicialización	k-means++, 10 reinicios (menor inercia)
Convergencia	Δ centroides < 1e-4 o 300 iteraciones (máx. observado: 47)
Semilla	20260913; ajuste con 12.000 píxeles, asignación de todos
Cluster fruto	puntaje de objeto: brillo, saturación, compacidad, centralidad, área, borde


La máscara de referencia solo se usa para calcular $J = |A \cap B| / |A \cup B|$.

Canales	Puntaje	Mín. borde	Máx. sat.	Oráculo
R	0.528	0.497	0.416	0.541
G	0.511	0.473	0.478	0.544
B	0.543	0.472	0.545	0.559
RG	0.557	0.550	0.477	0.575
RB	0.568	0.552	0.494	0.578
GB	0.538	0.496	0.516	0.565
RGB	0.552	0.535	0.499	0.574

Jaccard medio en desarrollo según la regla para elegir el cluster fruto. El puntaje de objeto es la mejor regla y queda cerca del oráculo: el límite es K-Means, no la regla.

Comparación de las siete combinaciones (Jaccard)

Jaccard medio en desarrollo



RB




mejor combinación ($J = 0.568$)

0.606

con post-procesado morfológico

Diferencia mejor-peor (G): 0.057, frente a DE entre imágenes ≈ 0.28 : ranking débil. R separa rojo de verde; B separa objetos saturados de fondos claros. Test: $J = 0.459$.

Ejemplos de segmentación (RB)



Fallo típico


Fondo bimodal o follaje brillante:
los dos clusters separan dos fondos
y el tomate queda repartido.

Post-procesado

Apertura + cierre (elipse 5×5),
relleno de huecos y eliminación de
componentes $< 1\%$. Mejora las 7
combinaciones.

Características extraídas del fruto segmentado

Descriptor	Justificación
$\bar{R}$, $\bar{G}$, $\bar{B}$	Mínimo exigido; la madurez pasa energía de G a R
$\bar{H}$ (circular)	Cromaticidad independiente del brillo; media circular
$\bar{S}$, $\bar{V}$	Saturación y brillo; separan color de iluminación
$\bar{a}^*$	Eje verde $\leftrightarrow$ rojo CIELAB: índice clásico de madurez
$\bar{b}^*$	Eje azul $\leftrightarrow$ amarillo, variable de control




Promedios calculados solo con los píxeles de la máscara K-Means final (entrenamiento).

10 Selección basada en el análisis exploratorio


Descriptor	d de Cohen	AUC univ.	Elegida
H	-4.07	0.981	sí
a*	3.31	0.957	no ($ r =0.92$ con H)
G	-1.74	0.882	sí
R	1.66	0.895	sí
V	0.81	0.755	no
S	0.66	0.697	no
b*	-0.38	0.625	no
B	-0.33	0.635	no

Regla: ordenar por $|d|$ y aceptar si $|r| \leq 0.85$ con las ya elegidas (máx. 3). Resultado: H, G, R.

Evita variables casi colineales: Bayes ingenuo contaría dos veces la misma evidencia.



Selección mediante SFS



Wrapper: se añade la variable que maximiza el AUC de validación cruzada 5x10 del mismo Bayes (solo entrenamiento). Se elige el prefijo más corto a ≤ 0.001 del mejor.

Seleccionadas

SFS: H, B, S, R

Análisis: H, G, R

¿Coinciden?

Sí en H (primera elegida) y R. SFS cambia G por B y S: optimiza el AUC conjunto, no la separación individual, y el criterio está saturado ($AUC \approx 0.98$, $DE \approx 0.04$). En 30 particiones SFS eligió 13 subconjuntos distintos; la regla de análisis repitió el suyo en 16.

Clasificador bayesiano y razón de verosimilitudes


Regla de decisión

$\ln \Lambda(x) = \ln p(x|\text{maduro}) - \ln p(x|\text{inmaduro}) \geq \ln \theta \rightarrow$
maduro

$p(x|\omega) = \prod N(x_j; \mu, \sigma^2)$ (gaussiano ingenuo, MV en
entrenamiento)

Relación con Bayes

Mínimo error: $\theta = P(\text{inmaduro})/P(\text{maduro})$. Variar θ recorre la
ROC. Con costos, θ incorpora C_{10} y C_{01} .





Punto de operación y evaluación

Estrategia	Entradas	$\ln \theta^*$	AUC val	AUC test	Exact.	Sens.	Espec.
Bayes + análisis	H, G, R	7.38	1.000	1.000	1.000	1.000	1.000
Bayes + SFS	H, B, S, R	7.21	1.000	1.000	1.000	1.000	1.000
PCA + Bayes	PC1, PC2, PC3	1.77	1.000	1.000	1.000	1.000	1.000


Criterio: índice de Youden en validación

$J = \text{sens} + \text{espec} - 1$. Sin costos definidos y clases balanceadas: ambos errores pesan igual. Umbral = punto medio entre puntuaciones; empates $\rightarrow$ centro.

Test de 12 imágenes sin errores: compatible con exactitud real ≥ 0.74 (Clopper–Pearson 95 %). No permite ordenar las estrategias.




PCA y número de componentes



PC	λ	Var. %	Acum. %
PC1	3.73	45.3	45.3
PC2	2.78	33.8	79.1
PC3	1.55	18.8	97.9
PC4	0.12	1.5	99.3
PC5	0.04	0.5	99.8


p = 3 (97.9 %)

Menor p con ≥ 95 % de varianza; coincide con el codo y con Kaiser ($\lambda_4 \ll 1$). PCA en entrenamiento sobre 8 variables estandarizadas; Bayes sobre PC1 –PC3.



Comparación de los tres clasificadores

30 particiones 60/20/20 independientes (protocolo completo en cada una)



- Partición principal: las tres empatan con AUC y exactitud 1.
- SFS ≈ análisis: diferencia de pocos errores, dentro de la variabilidad.
- PCA es consistentemente la peor: no usa la etiqueta y reintroduce B, V y b*.
- Con máscaras ideales, SFS es la única con errores (12): sobreajusta la selección.

0.978

Bayes + SFS (8 errores)

0.972



Bayes + análisis (10 errores)

0.950

PCA + Bayes (18 errores)

Exactitud media en test, 30 particiones, máscaras K-Means (360 predicciones).

Análisis integrado: segmentación → clasificación



$$\rho = -0.88$$

Jaccard vs desplazamiento de descriptores

- Peor máscara → descriptores más contaminados.
- Con máscara ideal, análisis y PCA no fallan: sus errores se deben a la segmentación.
- Tolera J bajos porque el tono medio no depende del brillo.
- Sin media circular, PCA pierde exactitud.

Máscara	Análisis	SFS	PCA
Referencia (ideal)	0	12	0
K-Means final	10	8	18
K-Means, H aritmético	10	15	39

Errores acumulados en 30 particiones (360 predicciones por celda).

Respuestas a las preguntas del proyecto

1. Mejor combinación

RB: $J = 0.568$ (0.606 con post-proceso).

2. ¿Por qué?

R separa rojo/verde; B separa fruto saturado de fondos claros.

3. Variables (EDA)

H circular y a^* ($|d| > 3$), luego G y R.

4. SFS

H, B, S, R. Coincide en H y R con el análisis.

5. Mejor estrategia

SFS $\approx$ análisis; análisis es más estable e interpretable.

6. Punto de operación

Youden en validación: sin costos, clases balanceadas.

7. Componentes

3 PCs: ≥ 95 % varianza (97.9 %), codo y Kaiser.

8. ¿PCA mejora?

No: empata en el test principal y es la peor al repetir.

9. Segmentación

Explica los errores; $\rho = -0.88$ con los descriptores.

Conclusiones

Segmentación

K-Means $k=2$ con RB + post-proceso: $J \approx 0.606$. Es el eslabón débil del sistema.

Madurez = tono

Con H como media circular, un Bayes con 3 variables clasifica casi perfectamente.

Selección

Análisis $\approx$ SFS en desempeño; el análisis es más estable. PCA no aporta.

Limitaciones

60 imágenes y test de 12: techo de desempeño.
Pesos heurísticos del cluster, sin textura ni forma.